СБЕР УНИВЕРСИТЕТ

ОБЗОР RAG

Егор КОЛОДИН

СБЕР УНИВЕРСИТЕТ

СОДЕРЖАНИЕ

1. Что такое RAG и зачем он нужен?
2. Embedding models
3. Rerankers
4. LangChain
5. Metrics

СБЕР УНИВЕРСИТЕТ

Что такое RAG и зачем он нужен?

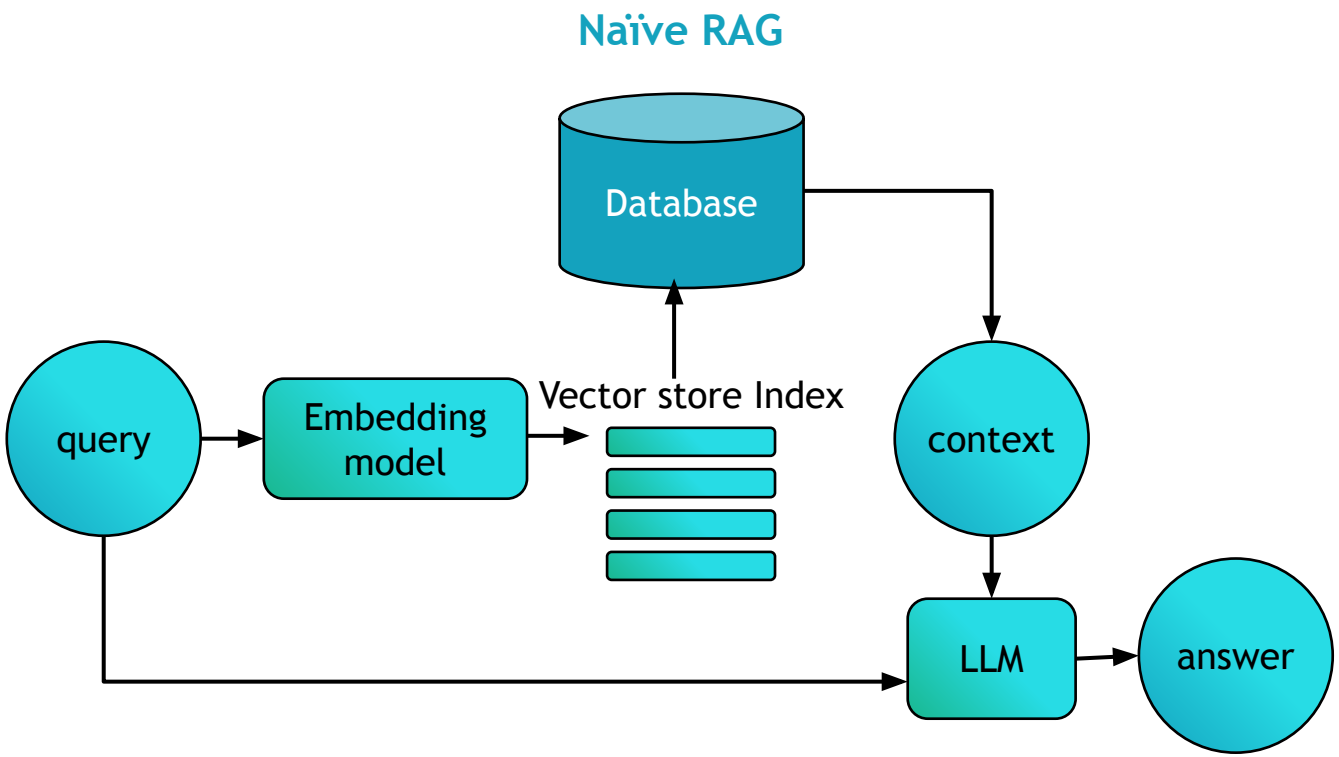

- Query преобразуется в эмбеддинг с помощью модели эмбеддингов.
- Vector Store Index используется для поиска релевантных документов по эмбеддингу запроса.
- Контекст извлекается из базы данных на основе близких векторов.
- LLM получает и запрос, и контекст, чтобы сгенерировать ответ.
- Подход называется Naive RAG (Retrieval-Augmented Generation) — простой,
  но мощный способ объединить поиск и генерацию.

СБЕР УНИВЕРСИТЕТ

Что такое RAG и зачем он нужен?

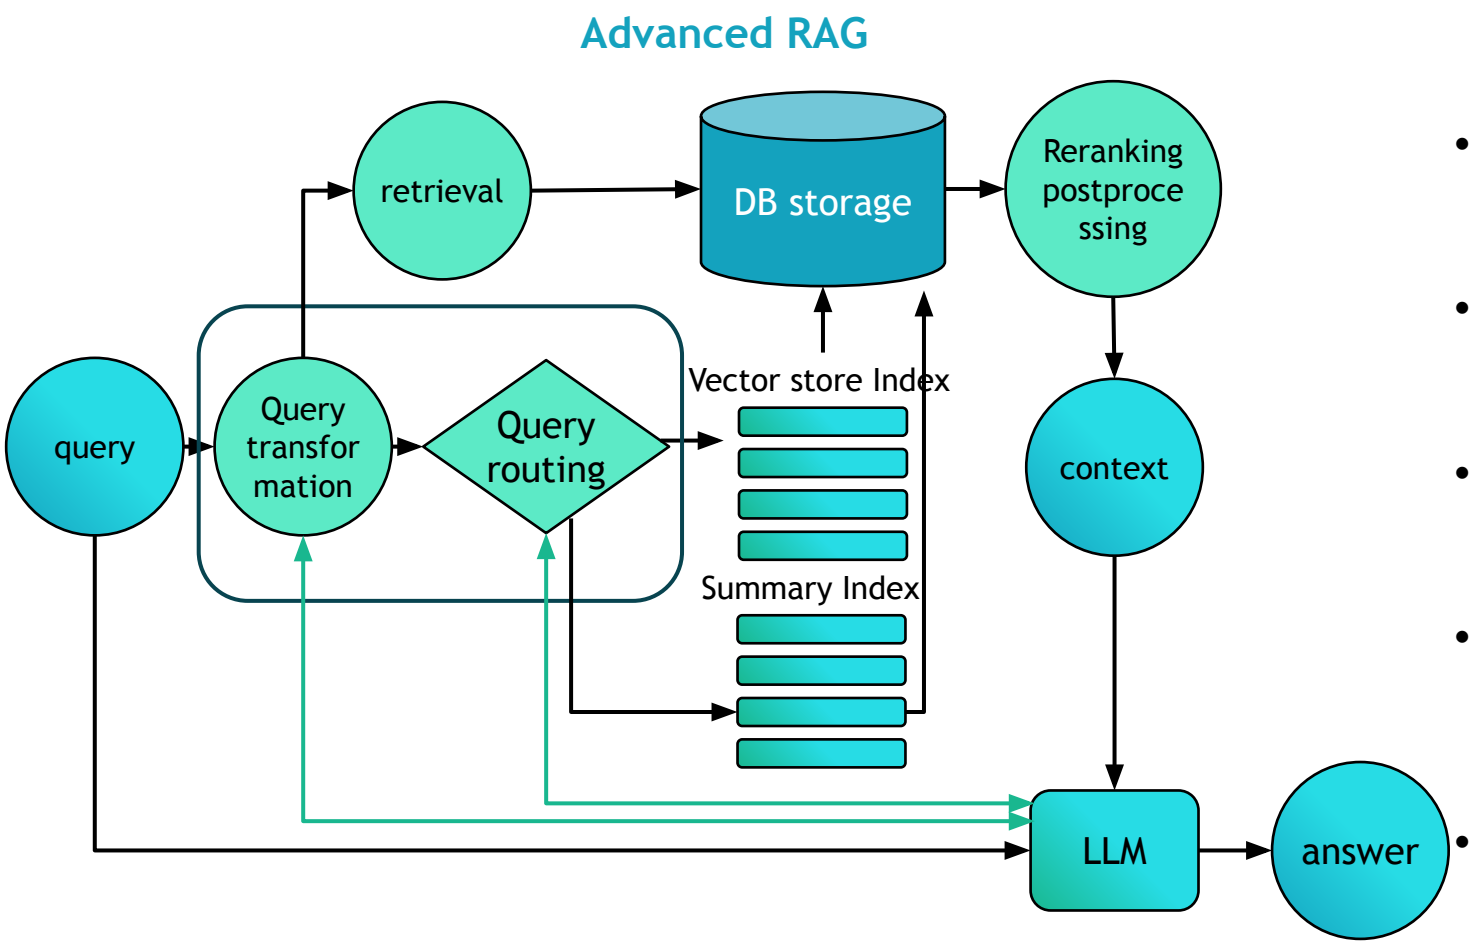

- Query transformation: переработка запроса (переформулировка, декомпозиция, генерация подзапросов)
- Query routing: выбор наиболее подходящего индекса или инструмента (векторный, summary и т.д.)
- Множественные индексы: векторные, summary, hybrid — выбор зависит от типа запроса
- Retrieval + reranking: поиск с последующим переупорядочиванием результатов для повышения качества
- LLM как оркестратор: может участвовать в преобразовании запроса, выборе инструментов, генерации промежуточных шагов
- Более гибкий и точный подход по сравнению с Naive RAG, но требует больше логики и вычислений

СБЕР УНИВЕРСИТЕТ

Embedding models

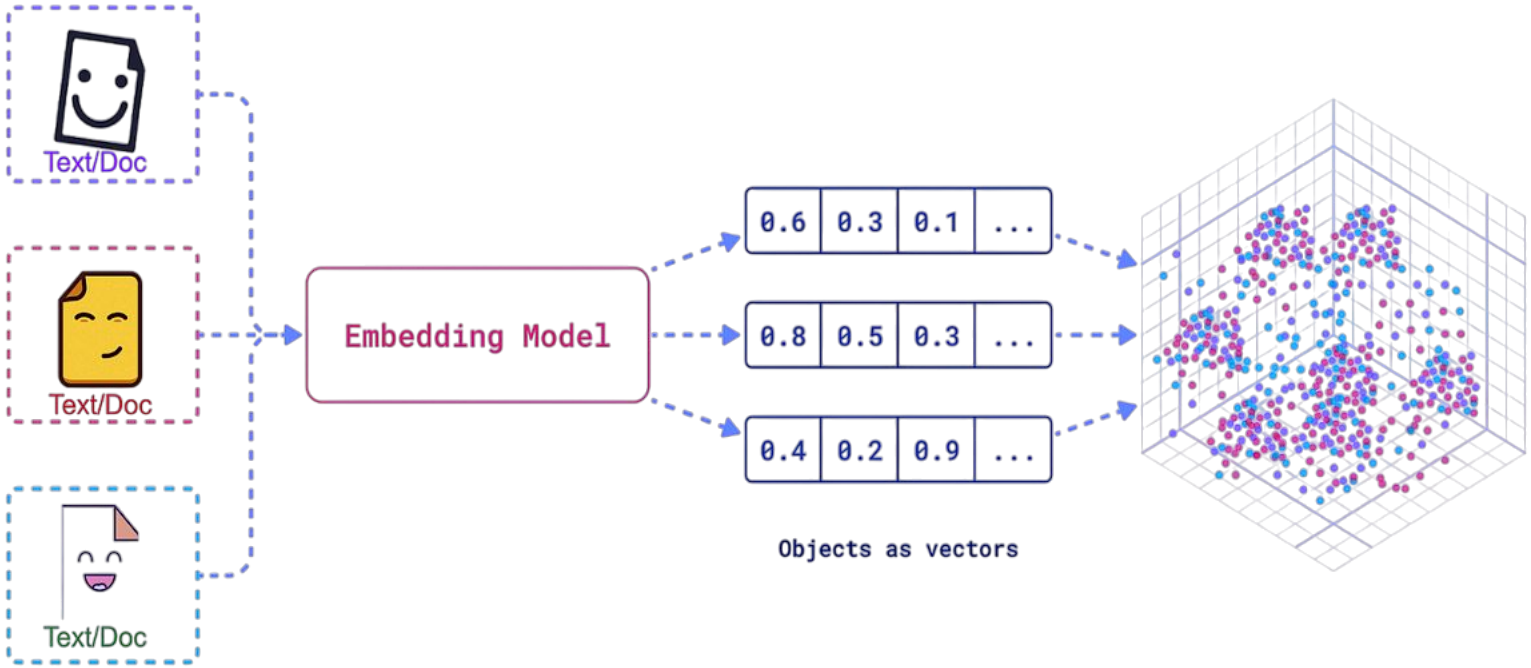

- Embedding-модель преобразует документы в числовые векторы фиксированной размерности
- Векторы отражают семантическое содержание текста: похожие тексты → близкие векторы
- Документы размещаются в векторном пространстве, где близость определяет релевантность
- Это ключевой шаг для поиска по смыслу (semantic search) и Retrieval-Augmented Generation
- Позволяет сравнивать тексты не по ключевым словам, а по значению

СБЕР УНИВЕРСИТЕТ

Rerankers

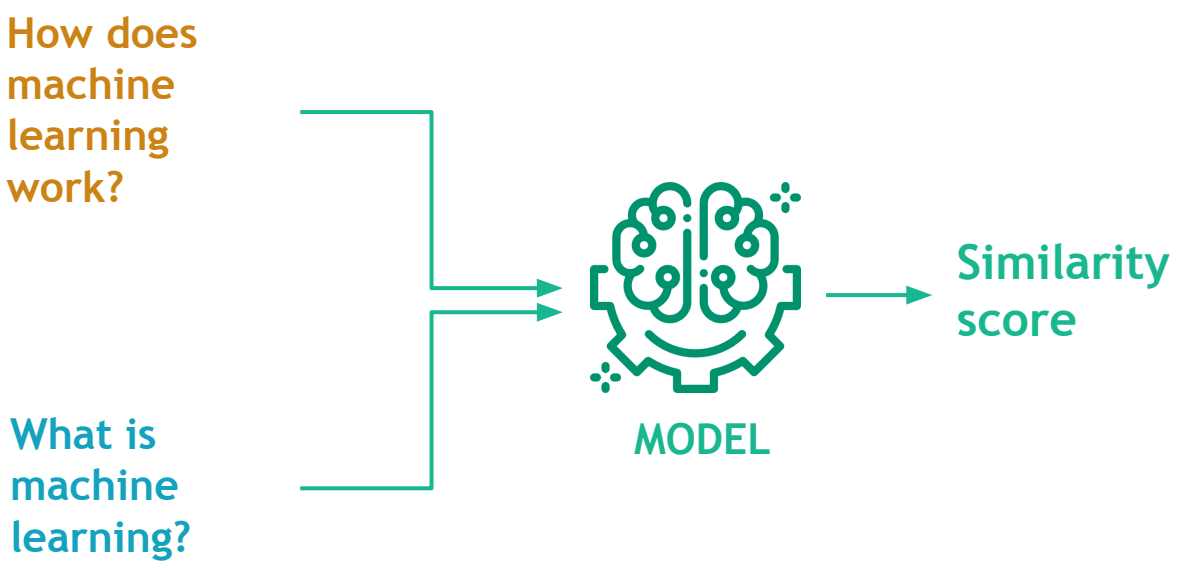

- Кросс-энкодеры оценивают релевантность пары (запрос, документ) совместно, а не по отдельности.
- Используют один трансформер, который принимает объединенный текст: [CLS] запрос [SEP] документ [SEP].
- Обеспечивают высокую точность в задачах ранжирования благодаря полной взаимосвязи между запросом и документом.
- Меньшая масштабируемость — требуется отдельный прогон модели для каждой пары.
- Отлично подходят для повторного ранжирования (re-ranking) топ-N кандидатов, отобранных биэнкодером или через векторный поиск.
- Баланс: точность выше, но скорость и ресурсы — ключевые ограничения при большом количестве документов.

СБЕР УНИВЕРСИТЕТ

LangChain

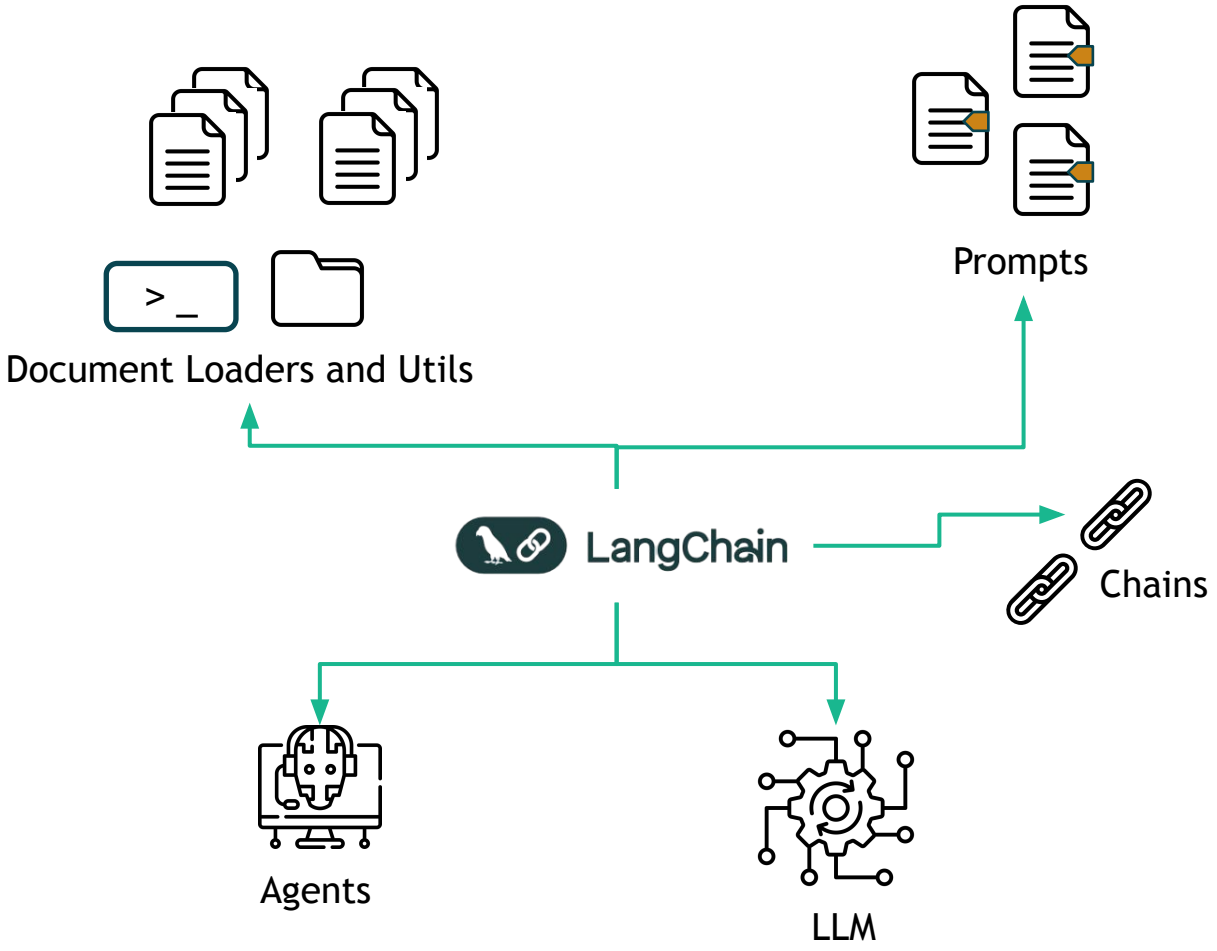

- LangChain — это фреймворк для создания LLM-приложений с использованием цепочек (chains) и агентов.
- Упрощает интеграцию LLM с внешними источниками знаний: базами данных, API, поиском и векторными хранилищами.
- Позволяет строить многошаговые пайплайны обработки: от обработки запроса до генерации ответа.
- Поддерживает модульную архитектуру: модели, память, инструменты, цепочки и агенты можно легко комбинировать.
- Имеет готовые компоненты для Retrieval-Augmented Generation (RAG), вопросов-ответов, чат-ботов и других кейсов .
- Активно развивается, поддерживает OpenAI, Hugging Face, Chroma, Pinecone и многие другие инструменты.

СБЕР УНИВЕРСИТЕТ

Metrics

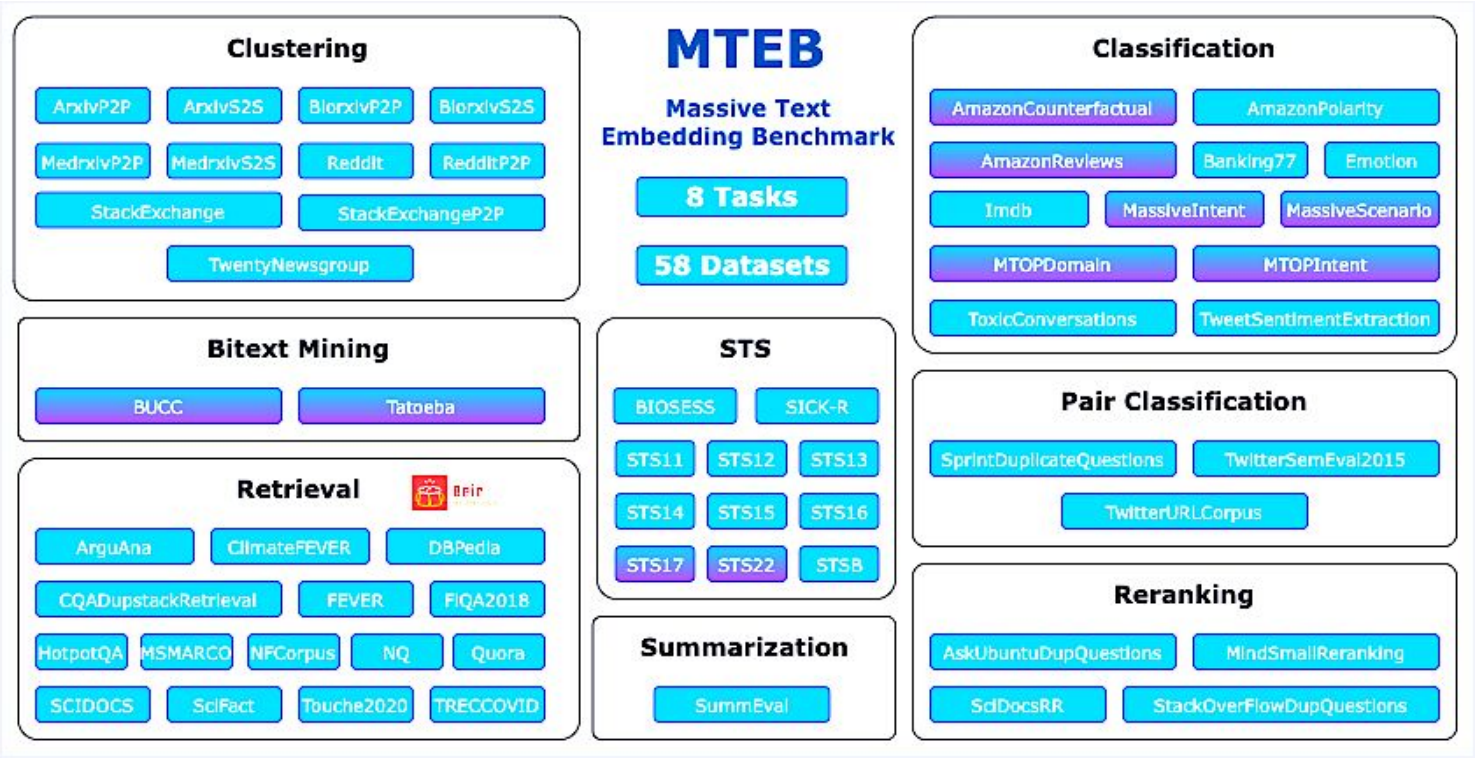

- MTEB — это масштабный бенчмарк для оценки качества текстовых эмбеддингов.
- Включает более 50 датасетов по 8 типам задач: классификация, кластеризация, поиск, ранжирование и др.
- Оценивает эмбеддинги без обучения на каждой задаче (zero-shot), что важно для универсальности моделей.
- Поддерживает сравнение моделей на различных языках и доменах.
- Часто используется для оценки моделей типа BERT, Sentence-BERT, E5, GTE, Instructor и других.
- Позволяет выявить сильные и слабые стороны эмбеддингов в разных практических сценариях.

СБЕР УНИВЕРСИТЕТ

Metrics

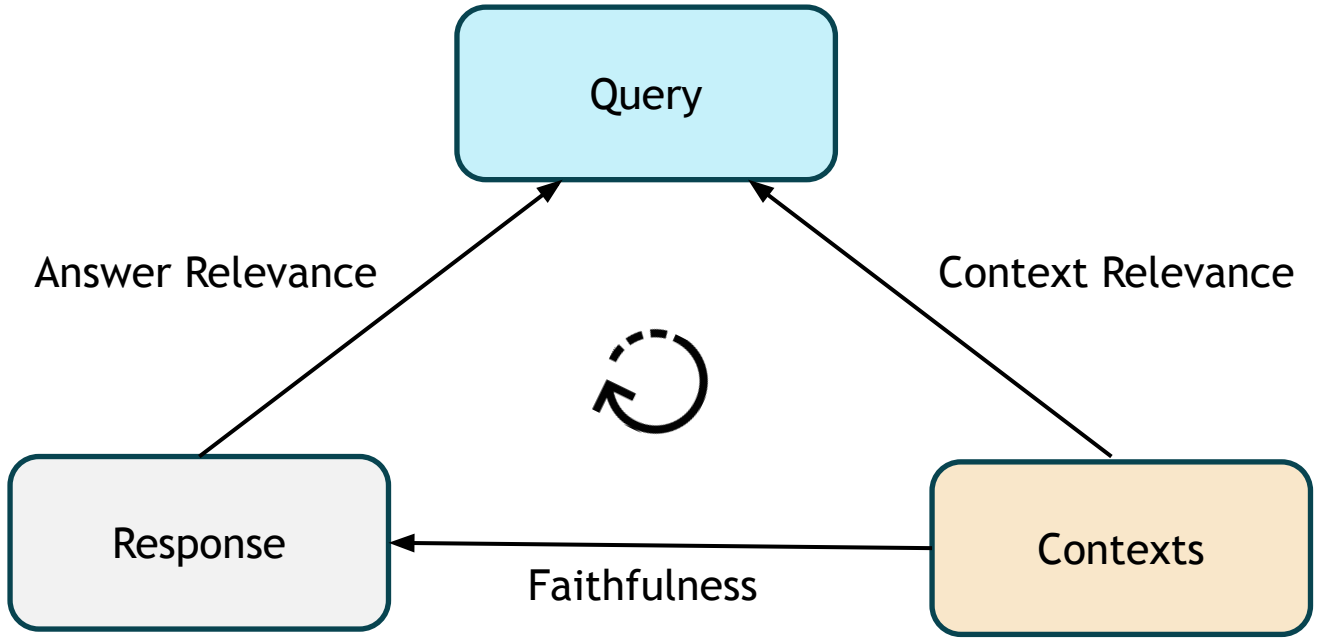

- RAGAs — это фреймворк для оценки качества RAG-систем (Retrieval-Augmented Generation).
- В отличие от классических метрик, фокусируется на ключевых аспектах: полноте извлечения, точности и согласованности генерации.
- Включает метрики:
  - Faithfulness — насколько ответ соответствует источнику;
  - Answer Relevance — насколько ответ соответствует вопросу;
- Context Precision & Recall — насколько релевантен извлеченный контекст.
- Позволяет проводить диагностику и улучшать отдельные компоненты RAG-пайплайна.
- Полезна для тестирования качества QA-систем, чатов и корпоративных ассистентов.

ВОПРОСЫ

СБЕР УНИВЕРСИТЕТ

СПАСИБО ЗА ВНИМАНИЕ!